個人消費預測系統

模型評估報告

三層評估框架：回歸層 × 決策層 × 成本層

2026

1. 模型架構說明

項目	ckh BiLSTM	GRU Aligned (lwc)	BiLSTM v2
架構	BiLSTM (2 層)	GRU + Attention (2 層)	BiLSTM + Attention (2 層)
輸入特徵數	5 (原始特徵)	10 (對齊特徵)	10 (對齊特徵)
Hidden Size	64 (雙向 = 128)	64	64 (雙向 = 128)
預訓練資料	無（從頭訓練）	Walmart 零售資料	Walmart 零售資料
集成策略	Single model	全 seeds 平均	暴力搜尋最佳組合

2. 輸入特徵說明

2.1 ckh BiLSTM：5 個原始特徵

特徵名稱	計算方式	意義
daily_expense	當日總花費（TWD）	最直接的消費信號
roll_7d_mean	過去 7 天均值	短期消費趨勢
roll_30d_mean	過去 30 天均值	長期個人基線
dow_sin	sin(2π × 星期幾 / 7)	週期性時間特徵（循環編碼）
dow_cos	cos(2π × 星期幾 / 7)	週期性時間特徵（循環編碼）

2.2 GRU Aligned / BiLSTM v2：10 個對齊特徵

這 10 個特徵均為「域不變（Domain-Invariant）」設計，使預訓練知識可從 Walmart 轉移到個人消費。

特徵名稱	計算方式	意義
zscore_7d	$(x - \mu_7) / \sigma_7$	相對短期波動（域不變）
zscore_14d	$(x - \mu_{14}) / \sigma_{14}$	相對中期波動（域不變）
zscore_30d	$(x - \mu_{30}) / \sigma_{30}$	相對長期波動（域不變）
pct_change_norm	$\Delta x / (\mu_{30} + \varepsilon)$，clip ±5	正規化日環比（域不變）
volatility_7d	$\sigma_7 / (\mu_7 + \varepsilon)$，clip 0-5	短期波動率（域不變）

is_above_mean_30d	$x > \mu_{30}$? 1 : 0	超過個人月均值的二元信號
pct_rank_7d	近 7 天消費的百分位排名	相對排名（0~1，域不變）
pct_rank_30d	近 30 天消費的百分位排名	相對排名（0~1，域不變）
dow_sin	sin(2π × 星期幾 / 7)	週期性時間特徵
dow_cos	cos(2π × 星期幾 / 7)	週期性時間特徵

3. 評估指標定義

3.0 混淆矩陣（Confusion Matrix）術語

術語	定義	說明
TP (True Positive)	模型預測「超標」且真的超標	正確的預警
TN (True Negative)	模型預測「正常」且真的正常	正確的放行
FP (False Positive)	模型預測「超標」但其實正常	誤報（假警報）
FN (False Negative)	模型預測「正常」但其實超標	漏報（最危險！）

決策層將問題轉換為二元分類：模型預測值 > 閾值 → 預警（Positive），否則 → 正常（Negative）。

3.1 Layer 1 — 回歸層指標

指標	公式	說明（越低越好）
MAE	mean(|y_true - y_pred|)	平均絕對誤差，單位：TWD
RMSE	sqrt(mean((y_true - y_pred)²))	對大誤差更敏感的均方根誤差
sMAPE	mean(|y_true-y_pred| / ((|y_true|+|y_pred|)/2)) × 100%	對稱平均絕對百分比誤差

3.2 Layer 2 — 決策層指標（全局）

預警觸發條件（Alert Threshold）

future_7d_sum > 個人近 30 日均值 × 1.5

其中： future_7d_sum = 未來 7 天實際消費總和（真實值）

個人近 30 日均值 = 以 X_test 中最後一天的 roll_30d_mean 作為個人基線

1.5 = 預警倍率（超過月均值 50% 即觸發）

指標	公式	說明
Precision（精確率）	TP / (TP + FP)	發出預警時，有多少是真正超標（越高越好）
Recall（召回率）	TP / (TP + FN)	真正超標時，有多少被預警到（越高越好）

F1	2 × Precision × Recall / (P + R)	Precision 與 Recall 的調和平均（越高越好）
FNR（漏報率）	FN / (TP + FN) = 1 - Recall	真正超標卻沒被抓到的比例（越低越好）
FPR（誤報率）	FP / (FP + TN)	正常情況下被誤報的比例（越低越好）

3.3 Layer 3 — 成本層與 Per-user 公平性指標

指標	公式	說明（越低越好）
Expected Cost（期望成本）	(FN × 3 + FP × 1) / n	漏報成本 3×，誤報成本 1×
Per-user MAE	每位用戶的 MAE	衡量模型對不同用戶的公平性
Per-user F1	每位用戶的 F1	衡量預警對不同用戶的公平性
Per-user FNR	每位用戶的 FNR	衡量漏報對不同用戶的公平性

注意：Layer 2 與 Layer 3 的 FNR 為何不同？

Layer 2 FNR = 把所有用戶的預測結果合併計算後，整體漏報率。

Layer 3 FNR mean = 先對每位用戶分別算 FNR，再對所有用戶取平均（簡單平均，每人權重相同）。

因為每位用戶的樣本數不同，小樣本用戶（如 user1 n=15，FNR=1.0）在 Layer 3 中佔相同權重，但在 Layer 2 中影響較小，所以 Layer 3 的 FNR mean 通常高於 Layer 2 的整體 FNR。

這是「宏觀平均（Macro Avg）」 vs「微觀平均（Micro Avg）」的差異，Layer 3 更能揭示模型對個別用戶是否公平。

4. 實驗結果

測試集共 642 個樣本，涵蓋 7 位用戶，時間依序分割（70/15/15%）。

4.1 Layer 1 — 回歸層結果

模型	MAE (↓)	RMSE (↓)	sMAPE (↓)
ckh BiLSTM（同學）	**745.79**	—	—
GRU Aligned (lwc)	790.00	**1164.24**	**79.03%**
BiLSTM v2（我們最佳）	750.62	1172.16	81.17%

Per-user MAE 分析

模型	Per-user MAE 均值	Per-user MAE 最大值	Per-user MAE 標準差
ckh BiLSTM	738.83	1497.26 (user8)	359.75
GRU Aligned (lwc)	771.77	1426.03 (user13)	**331.60**
BiLSTM v2	740.60	1364.04 (user13)	351.89

4.2 Layer 2 — 決策層結果（全局）

模型	Precision (↑)	Recall (↑)	F1 (↑)	FNR (↓)	FPR (↓)	Expected Cost (↓)
ckh BiLSTM	**0.364**	0.354	**0.359**	0.646	—	**0.586**
GRU Aligned (lwc)	0.354	0.310	0.331	0.690	0.165	0.595
BiLSTM v2	0.299	0.241	0.267	0.759	0.165	0.642

4.3 Layer 3 — Per-user 公平性摘要

模型	F1 mean	F1 min	FNR mean	FNR max	Cost mean	Cost max	Worst MAE user
ckh BiLSTM	**0.225**	0.0	**0.703**	1.0	**0.558**	—	user8 (1497)
GRU Aligned (lwc)	0.216	0.0	0.751	1.0	0.569	0.972	user13 (1426)
BiLSTM v2	0.174	0.0	0.790	1.0	0.618	0.972	user13 (1364)

4.4 各用戶詳細結果

ckh BiLSTM（同學）

User	n	MAE	NMAE	F1	Recall	FNR	FPR	Cost	Alert %
user1	15	572.42	0.9139	0.000	0.000	1.000	—	0.600	20.0%
user7	51	932.02	0.5279	0.619	0.464	0.536	0.081	0.529	51.0%
user8	50	1497.26	0.5927	0.516	0.348	0.652	0.135	0.568	47.9%
user9	72	105.38	0.7063	0.054	1.000	0.000	1.000	0.958	2.8%
user13	75	1218.53	0.5432	0.471	0.333	0.667	0.065	0.598	40.0%
user16	53	805.80	0.3965	0.348	0.250	0.750	0.108	0.698	37.7%
其他...	326	—	—	—	—	—	—	—	—

GRU Aligned (lwc)

User	n	MAE	NMAE	F1	Recall	FNR	FPR	Cost	Alert %
user1	15	647.99	1.0349	0.000	0.000	1.000	—	0.600	20.0%
user7	51	1025.88	0.5811	0.619	0.464	0.536	0.081	0.529	51.0%
user8	50	1281.21	0.5071	0.406	0.261	0.739	0.135	0.628	47.9%
user9	72	146.45	0.9809	0.054	1.000	0.000	1.000	0.958	2.8%
user13	75	1426.03	0.6354	0.375	0.250	0.750	0.065	0.631	40.0%
user16	53	962.54	0.4740	0.432	0.313	0.688	0.108	0.651	37.7%
其他...	326	—	—	—	—	—	—	—	—

BiLSTM v2（我們最佳模型）

User	n	MAE	NMAE	F1	Recall	FNR	FPR	Cost	Alert %
user1	15	543.67	0.8681	0.000	0.000	1.000	—	0.600	20.0%
user7	51	1052.81	0.5962	0.619	0.464	0.536	0.081	0.529	51.0%
user8	50	1328.00	0.5256	0.516	0.348	0.652	0.135	0.568	47.9%
user9	72	146.56	0.9822	0.054	1.000	0.000	1.000	0.958	2.8%
user13	75	1364.04	0.6079	0.356	0.222	0.778	0.065	0.647	40.0%
user16	53	962.54	0.4740	0.432	0.313	0.688	0.108	0.651	37.7%
其他...	326	—	—	—	—	—	—	—	—

5. 關鍵洞察與結論

Layer 1 關鍵發現：MAE 差異 <1%，在統計誤差範圍內

ckh BiLSTM (745.79) vs BiLSTM v2 (750.62)：差距 4.83 TWD，約 0.6%。

BiLSTM v2 的 z-score 特徵雖捨棄絕對金額尺度，但配合 Walmart 預訓練後仍能學到有效模式。

GRU Aligned 的 Per-user MAE 標準差最低（331.60），代表對不同用戶最公平。

Layer 2 關鍵發現：ckh BiLSTM 在 F1 與 Cost 上最佳

ckh BiLSTM：F1=0.359，Expected Cost=0.586（全局最佳）。

原始特徵保留絕對金額資訊，對超標閾值的判斷更直接有效。

三個模型的 FPR 都相近（~0.165），但 FNR 差異明顯，漏報是主要問題。

以成本觀點：FN 的懲罰為 FP 的 3 倍，因此 FNR 高的模型代價更大。

Layer 3 關鍵發現：user9 是全部模型的特殊難題

user9（n=72）在三個模型中 FPR 均為 1.0：每次預測「正常」，但用戶幾乎從不超標（alert 率僅 2.8%）。

這不是模型設計缺陷，而是 user9 的消費行為極度穩定，「超標」極為罕見，模型難以學習。

user13 是 MAE 最差的用戶（GRU: 1426，BiLSTM v2: 1364），消費波動極大。

Layer 3 的 FNR mean 均高於 Layer 2（Macro 平均 vs Micro 平均），顯示模型對小樣本用戶保護不足。

5.4 綜合評比

面向	最佳模型	數值	備註
MAE（最低）	**ckh BiLSTM**	745.79	原始特徵保留金額資訊
Per-user MAE 標準差（最公平）	**GRU Aligned (lwc)**	331.60	z-score 特徵更均衡
F1 Score（最高）	**ckh BiLSTM**	0.359	決策判斷最準確
Expected Cost（最低）	**ckh BiLSTM**	0.586	商業成本最低
Transfer Learning 驗證	**BiLSTM v2**	MAE 差距 <1%	Walmart → 個人遷移成立

三層評估框架讓我們不只是「預測數字」，而是評估這個系統在真實場景中的商業價值與公平性。